UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA

FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE

PROIECT
IDENTIFICAREA SISTEMELOR
2025-2026

STUDENT: Tudor Adrian-Raul-Ștefănel

PROF. ÎNDRUMĂTOR: dr. Ing. Mircea Șuscă

GRUPA: 30133

CUPRINS

1. INTRODUCERE 2
2. CONSIDERAȚII TEORETICE 2
Sistem de ordinul II 3
Sistem de tip spațiul stărilor 3
Indicatori de performanță 3
3. IDENTIFICAREA SISTEMELOR DE ORDIN II UTILIZÂND METODA REGRESIEI LINIARE . 5
3.1. Datele sistemului analizat 5
3.2. Determinarea factorului de proporționalitate K 5
3.3 Determinarea componentei reale a polilor 6
3.4 Determinarea componentei imaginare a polilor 9
3.5 Determinarea pulsației naturale si a factorului de amortizare 9
3.6 Validarea 10
3.7 Funcția de cost și Eroarea medie pătratică 11
4. IDENTIFICAREA SISTEMELOR DE ORDIN II UTILIZÂND SEMNALE CHIRP 11
4.1. Datele semnalului analizat 11
4.2. Determinarea factorului de proporționalitate K 12
4.3. Determinarea modulului de rezonanță 13
4.4. Determinarea pulsației naturale si factorului de amortizare 13
4.5. Validarea 14
4.6. Funcția de cost și Eroarea medie pătratică 15
5. IDENTIFICAREA SISTEMELOR UTILIZÂND METODE PARAMETRICE 16
5.1. Scopul principal 16
5.2. Pre-procesarea datelor 17
5.3. Estimarea Modelelor 18
5.3.a) Modele variate prin autocorelație 18
5.3.b) Modele variate prin intercorelație 20
5.3.c) Modele de altă natură 21
5.4. Poli și zerouri 22
5.5. Concluzie 23

1. INTRODUCERE

Analiza sistemelor dinamice constituie fundamentul necesar pentru înțelegerea comportamentului acestora, fiind o etapă indispensabilă în dezvoltarea unor strategii performante de reglare și identificare. În practica inginerească, situațiile în care modelul matematic analitic lipsește sunt frecvente, impunând deducerea acestuia prin prelucrarea datelor experimentale. Astfel, identificarea sistemelor facilitează obținerea unui model capabil să descrie fidel relația intrare-ieșire, instrument esențial pentru analiză, simulare și proiectarea algoritmilor de control.

Lucrarea explorează principalele direcții în identificarea sistemelor: abordările neparametrice și cele parametrice. Metodele neparametrice au avantajul de a determina caracteristicile sistemului fără a necesita o structură predefinită a modelului. Pe de altă parte, metodele parametrice presupun o structură cunoscută a modelului și se concentrează pe estimarea numerică a coeficienților acestuia, utilizând seturile de date achiziționate.

2. CONSIDERAȚII TEORETICE

Identificarea sistemelor dinamice reprezintă procesul de determinare a unui model matematic capabil să descrie relația dintre intrările și ieșirile unui sistem, utilizând date experimentale. Această etapă este fundamentală în inginerie și automatică, în special în situațiile în care modelul teoretic (fenomenologic) al procesului nu este disponibil sau este prea complex.

În literatura de specialitate, metodele de identificare se clasifică în două categorii majore:

- **Metode neparametrice:**

Aceste metode permit analiza caracteristicilor dinamice prin studierea răspunsului sistemului la semnale de test specifice (ex. semnal treaptă, semnal de tip chirp). Principalul avantaj constă în faptul că nu necesită cunoașterea a priori a structurii procesului, rezultatele fiind utilizate pentru estimarea funcției de transfer și a parametrilor globali.

- **Metode parametrice:**

Abordarea parametrică presupune selectarea unei structuri a modelului, scopul identificării fiind obținerea unui model matematic care să aproximeze cât mai fidel comportamentul real al sistemului. În cadrul acestui proiect, s-a utilizat identificarea de tip **offline**, pe baza seturilor de date colectate anterior. Astfel, s-a generat un model aproximativ care reproduce dinamica sistemului, fără a implica extragerea directă a parametrilor fizici.

Sistem de ordinul II

Un sistem liniar, continuu, de ordinul doi poate fi descris prin funcția de transfer:

$$H(s) = \frac{Y(s)}{U(s)} = \frac{K\omega_n^2}{(s^2 + 2\zeta\omega_n s + \omega_n^2)}$$

Sistem de tip spațiul stărilor

- Forma continuă în spațiul stărilor poate fi scrisă astfel:

$$\begin{cases} \dot{\mathbf{x}} = A\mathbf{x} + Bu \\ y = C\mathbf{x} + Du \end{cases}$$

unde:

$$A = \begin{bmatrix} 0 & 1 \\ -\omega_n^2 & -2\zeta\omega_n \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ K\omega_n^2 \end{bmatrix}, \quad C = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad D = 0$$

Indicatori de performanță

Eroarea medie pătratică (MSE) oferă o măsură a erorii "medii" dintre cele două semnale și penalizează mai puternic deviațiile mari:

$$\varepsilon_{MSE} = \frac{1}{N}\sum_{k=1}^{N}(y[k] - \hat{y}[k])^2$$

Funcția de cost *J* reprezintă suma erorilor pătratice pe întreg setul de date și este frecvent folosită ca criteriu de optimizare în identificare:

$$J = \sum_{k=1}^{N}(y[k] - \hat{y}[k])^2$$

Indicatorul de potrivire (FIT) reprezintă un indicator de validare utilizat pentru evaluarea modelelor din metode parametrice:

$$FIT = 100\left(1 - \frac{(||y-\hat{y}||)}{(||y-\bar{y}||)}\right)$$

METODE NEPARAMETRICE

3. IDENTIFICAREA SISTEMELOR DE ORDIN II UTILIZÂND METODA REGRESIEI LINIARE

3.1. Datele sistemului analizat

Identificarea s-a realizat pentru perechea impusă $(m,n) = (3,9)$, de unde a rezultat acest grafic:

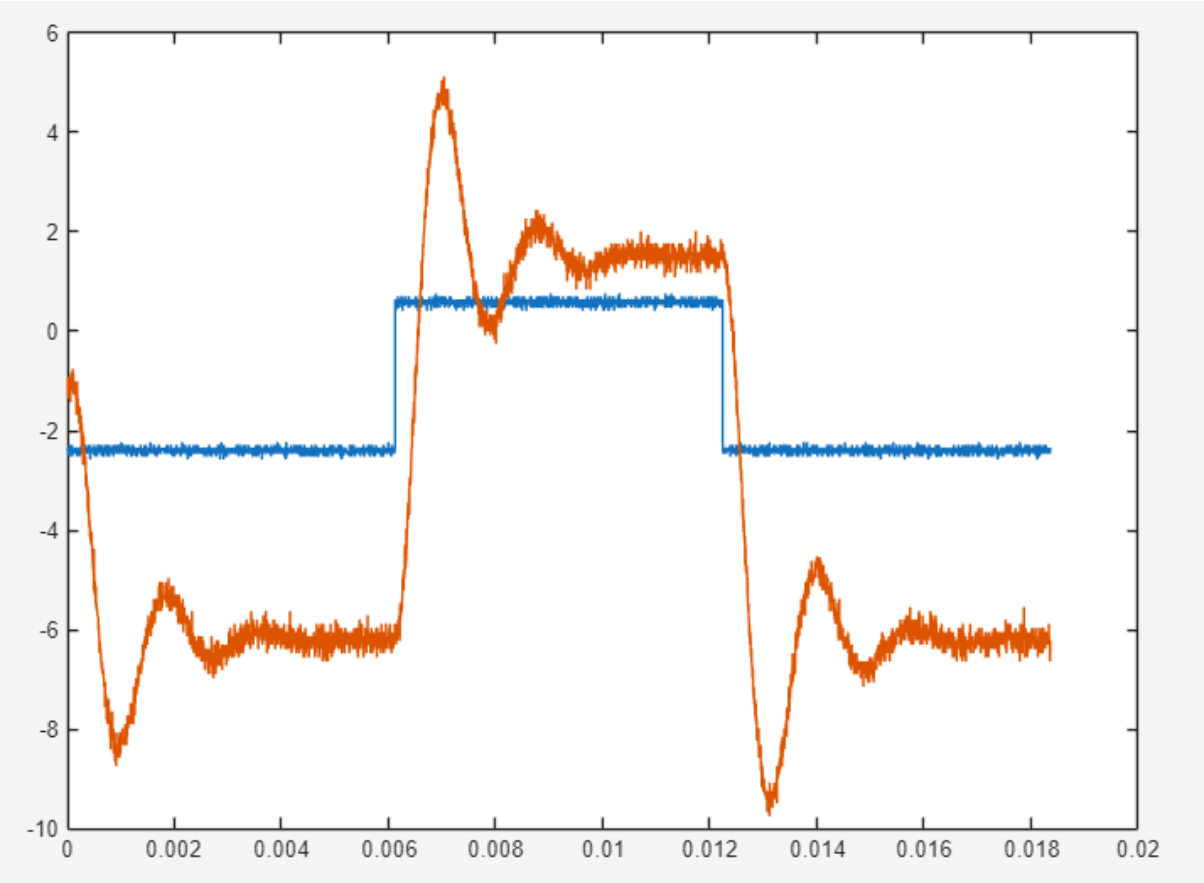

Figura 3.1

3.2. Determinarea factorului de proporționalitate K

Factorul de proporționalitate se calculează cu ajutorul relației:

$$K = \frac{\overline{y_{st}} - \overline{y_0}}{\overline{u_{st}} - \overline{u_0}}$$

unde $\overline{y_0}$ și $\overline{u_0}$ reprezintă valorile medii ale semnalelor înainte de aplicarea treptei, iar $\overline{y_{st}}$ și $\overline{u_{st}}$ sunt mediile calculate pe intervalul de regim staționar

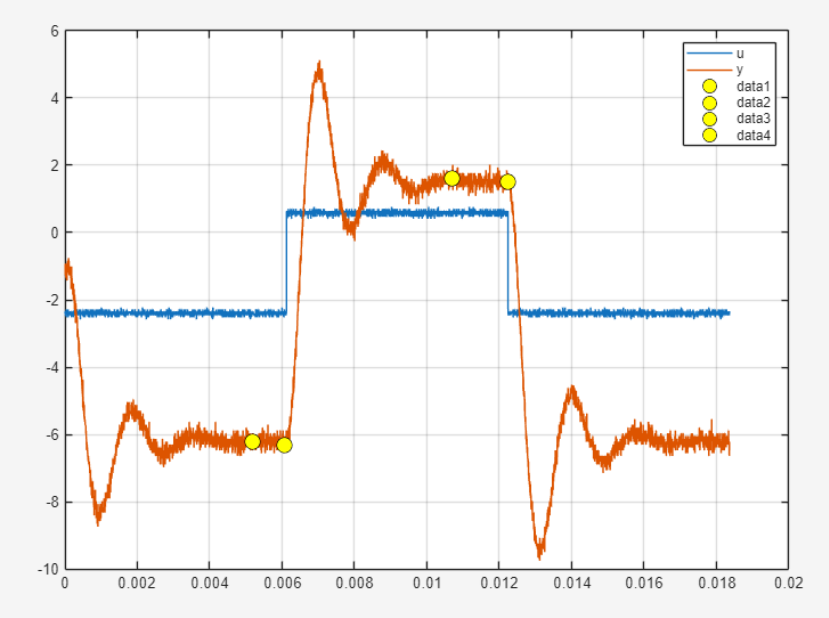

Figura 3.2

Datele numerice au fost preluate din grafic cu ajutorul **Data Cursor,** folosind funcția **Export Data Cursor to Workspace** și exportate în **MATLAB** pentru procesare. Astfel, se obține valoarea aproximativă:

K ≈ 2.6130

3.3 Determinarea componentei reale a polilor

Sistemul analizat este de ordinul al doilea, având funcția de transfer

$$H(s) = \frac{Y(s)}{U(s)} = \frac{K\omega_n^2}{(s^2+2\zeta\omega_n s+\omega_n^2)}$$

Aceasta are doi poli complex-conjugați:

$$s_{1,2} = -\zeta\omega_n \pm j\omega_n\sqrt{(1-\zeta^2)}$$

De unde reies următoarele:

$$Re\{s_{1,2}\} = -\zeta\omega_n \qquad Im\{s_{1,2}\} = \omega_n \cdot \sqrt{(1-\zeta^2)}$$

Pentru a determina parametrii sistemului, este necesară o metodă de identificare care să permită estimarea precisă a relației dintre intrările și ieșirile sistemului. În acest context, utilizăm ***regresia liniară***.

Metoda regresiei liniare este utilizată pentru determinarea parametrilor modelului pe baza măsurătorilor experimentale. Pentru un sistem de ordinul doi, scopul este obținerea coeficienților ζ (amortizare) și ω_n (pulsație naturală).

Procesul constă în selectarea unei porțiuni relevante din răspunsul la treaptă, cuprinsă între punctele i5 și i6, care să includă oscilațiile sistemului. Graficul rezultat evidențiază vârfurile oscilațiilor și deviația acestora față de valoarea finală stabilizată, y_{st}.

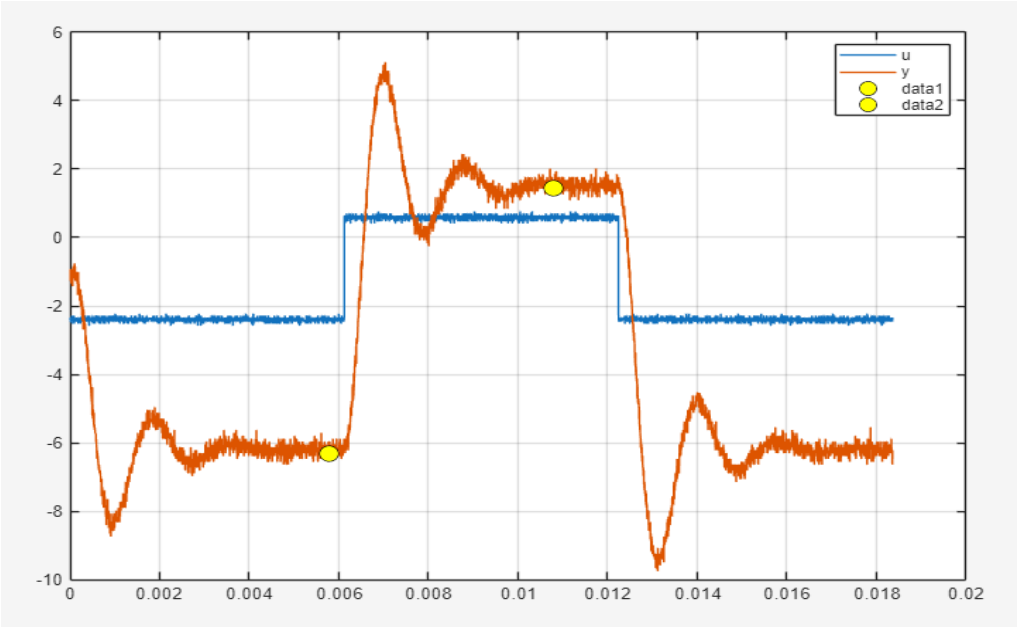

Figura 3.3: Indicii i5 și i6.

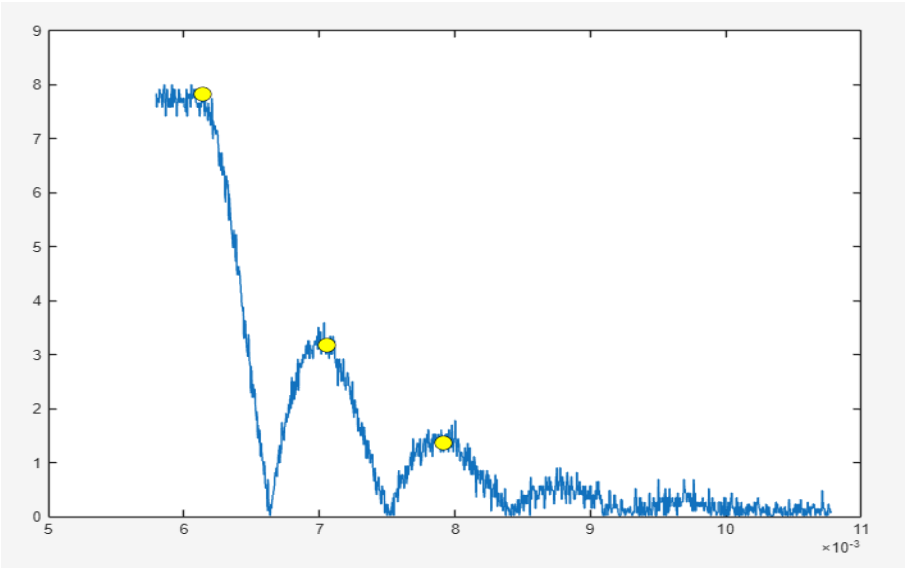

Figura 3.4: Intervalul cu oscilațiile semanlului.

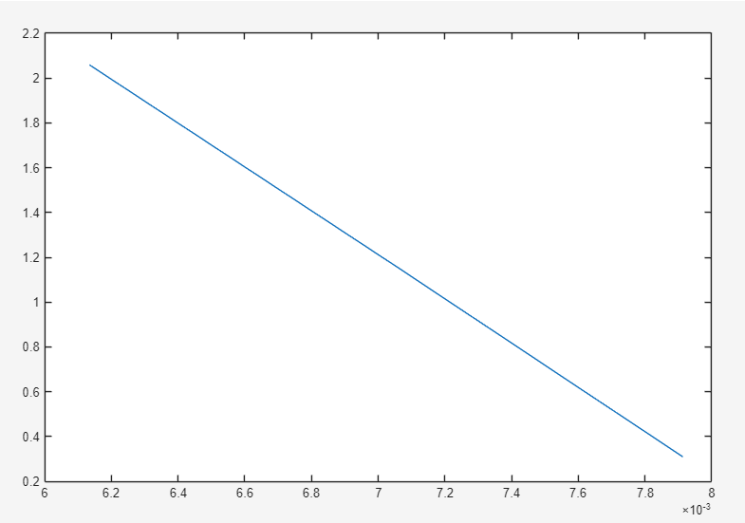

Figura 3.5: Dreapta ce aproximează perechile de măsurători

Pentru determinarea exactă a dreptei, este utilizată regresia liniară în formă matriceală:

$$\boldsymbol{\theta} = \begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} \sum t_k^2 & \sum t_k \\ \sum t_k & N \end{pmatrix}^{-1} \cdot \begin{pmatrix} \sum x_k t_k \\ \sum x_k \end{pmatrix}$$

Prima componentă a vectorului θ reprezintă partea reală a polilor.

Valoarea numerică obținută este:

Re = -983.2656

3.4 Determinarea componentei imaginare a polilor

Pulsația oscilațiilor este dictată de partea imaginară a polilor sistemului. Pentru a o determina, este necesară extragerea perioadei de oscilație din graficul răspunsului la treaptă.

În acest sens, au fost selectate două puncte cheie: i11, reprezentând momentul inițial al declanșării treptei, și i12, reprezentând momentul în care semnalul atinge amplitudinea maximă. Intervalul de timp cuprins între aceste două puncte corespunde unei semi-perioade de oscilație (jumătate din ciclul complet).

Pentru a obține perioada completă , valoarea determinată se înmulțește cu doi:

$$T_{osc} = 2 \cdot (i_{12} - i_{11})$$

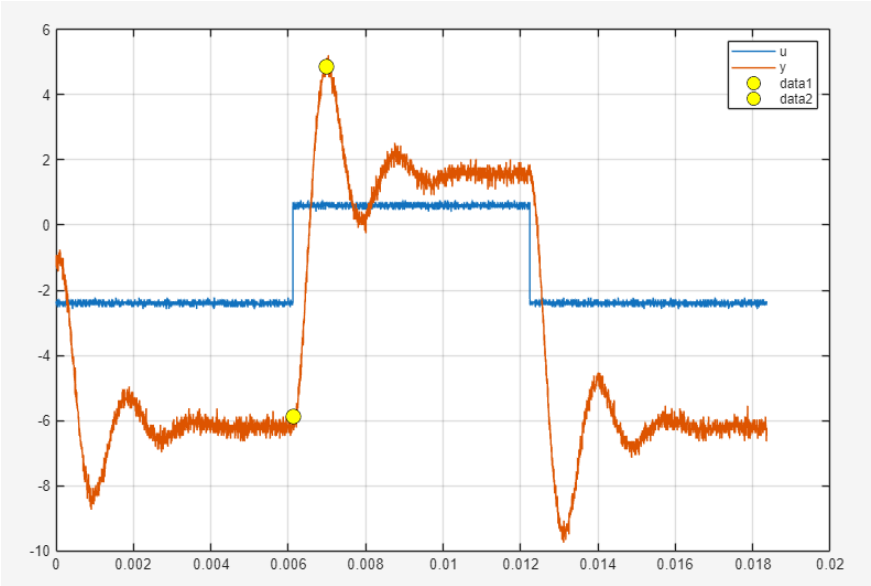

Figura 3.6: Indicii i11 si i12

Componenta imaginară a polilor se poate calcula cu relația:

$$Im = \frac{2\pi}{T_{osc}}$$

Astfel, valoarea numerică obținută este:

$$Im = 3.6239 \cdot 10^3$$

3.5 Determinarea pulsației naturale si a factorului de amortizare

Acești doi parametrii le putem afla folosind aceste două relații:

$$\omega_n = \sqrt{\left(Re\{s_{1,2}\}\right)^2 + \left(Im\{s_{1,2}\}\right)^2} \qquad \xi = -\frac{Re\{s_{1,2}\}}{\omega_n}$$

Astfel, valorile numerice sunt:

$$\omega_n = 3.7512 \cdot 10^3 \qquad \zeta = 0.2582$$

3.6 Validarea

Validarea se realizează prin suprapunerea răspunsului modelului peste răspunsul măsurat, folosind aceeași intrare $u(t)$. Răspunsul sistemului modelat se obține prin simulare în timp cu lsim, iar rezultatul este comparat direct cu semnalul de ieșire original.

Pentru o verificare suplimentară, modelul este exprimat și în spațiul stărilor, echivalent cu funcția de transfer anterioară, ceea ce permite simularea cu condiții inițiale impuse:

$$A = \begin{bmatrix} 0 & 1 \\ -\omega_n^2 & -2\zeta\omega_n \end{bmatrix}, \qquad B = \begin{bmatrix} 0 \\ K\omega_n^2 \end{bmatrix}, \qquad C = [1 \quad 0], \qquad D = 0$$

Rezultatul identificării, obținute prin simularea funcției de transfer, spațiului stărilor pe graficul inițial este acesta:

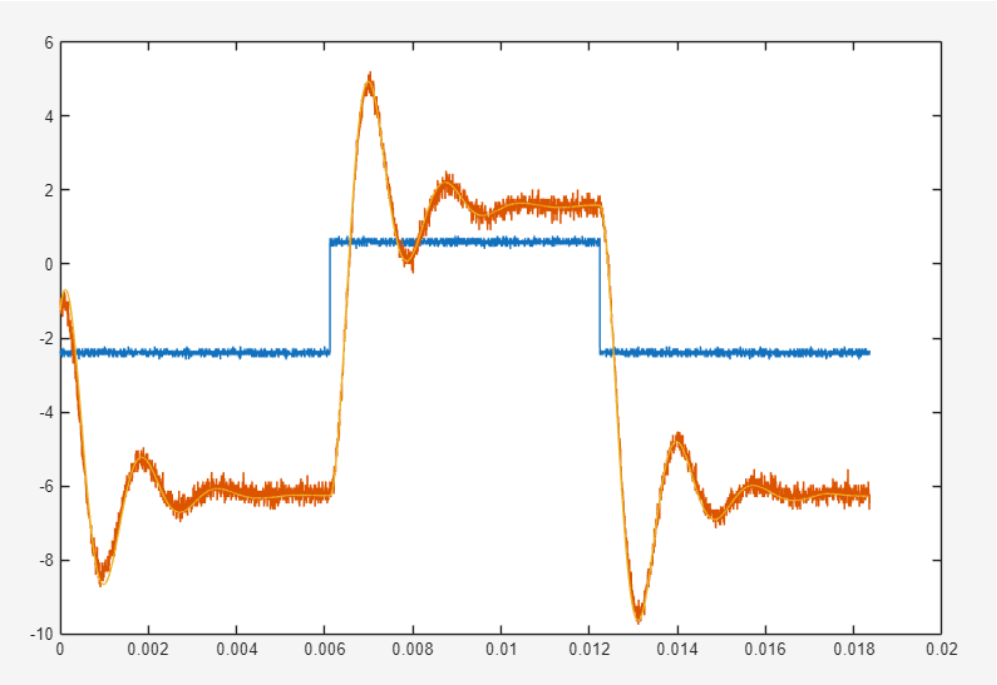

Figura 3.7: Rezultatul validării

3.7 Funcția de cost și Eroarea medie pătratică

Pentru calcularea celor doi indici de performanță vom folosi:

$$J = \frac{1}{\sqrt{N}} \cdot \left|\left|y - y_{sim}\right|\right| \qquad \varepsilon_{MSE} = \frac{||y - y_{sim}||}{||y - \bar{y}||} \cdot 100$$

Astfel, valorile calculate sunt:

$$J = 0.0014 \qquad \varepsilon_{MSE} = 5.3384$$

4. IDENTIFICAREA SISTEMELOR DE ORDIN II UTILIZÂND SEMNALE CHIRP

4.1. Datele semnalului analizat

Identificarea s-a realizat pentru perechea impusă $(m,n) = (3,9)$, de unde a rezultat acest semnal:

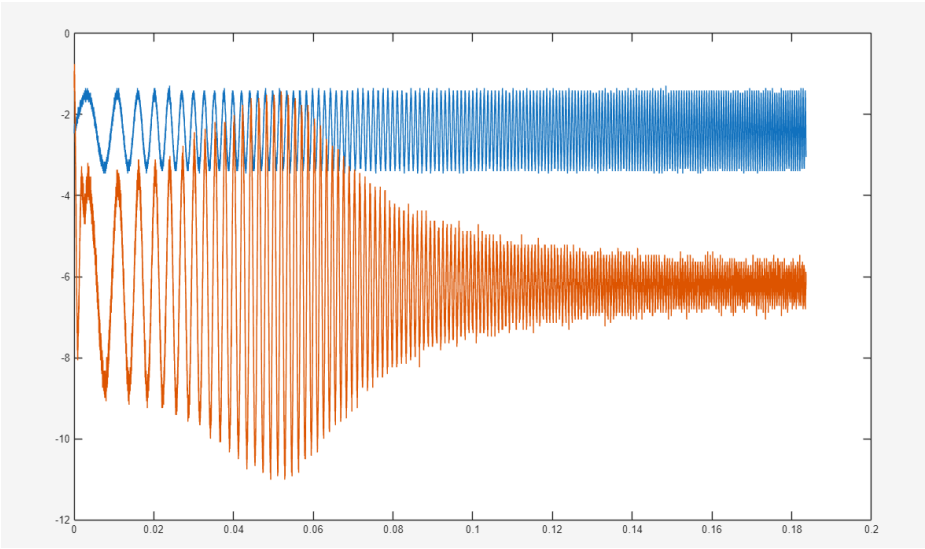

Figura 4.1

Însă eu am decis sa aplic un filtru Savitzkyy-Golay pentru a putea micșora eroarea medie pătrratică. După filtrare, semnalul arată astfel

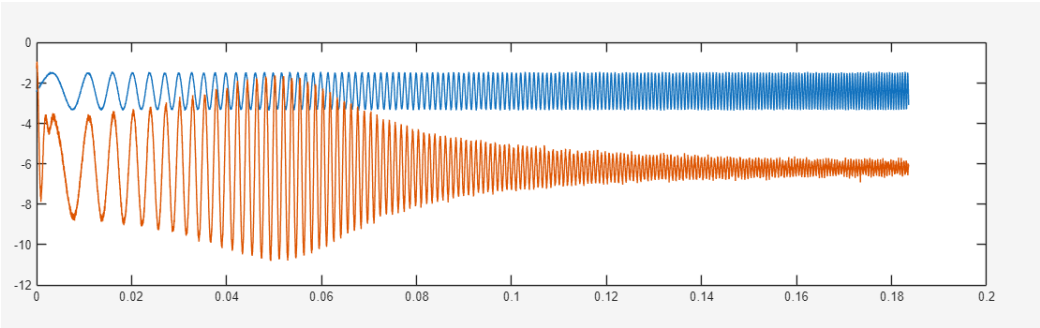

Figura 4.2

4.2. Determinarea factorului de proporționalitate K

Factorul de proporționalitate se calculează cu ajutorul relației:

$$K = \frac{A_y}{A_u}, \qquad \text{, în cazul meu } K \approx 2.5732$$

unde A_y este jumatate din suma coordonatelor Y ale lui y_{max} si y_{min} din prima oscilație, iar A_u este jumatate din suma coordonatelor Y ale lui x_{max} si x_{min} din prima oscilație.

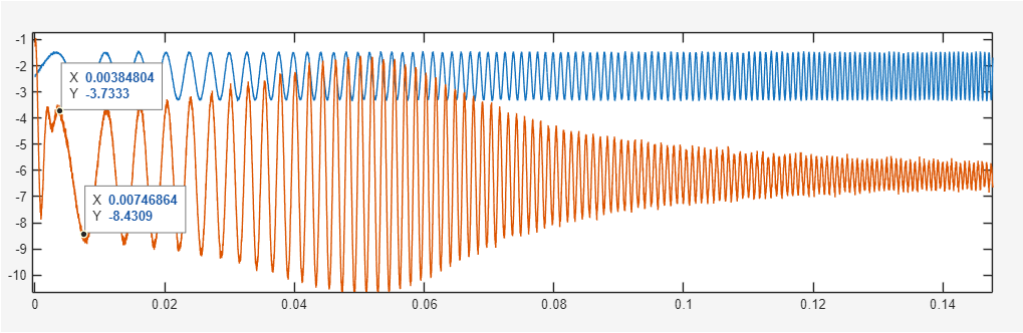

Figura 4.3 - Ay

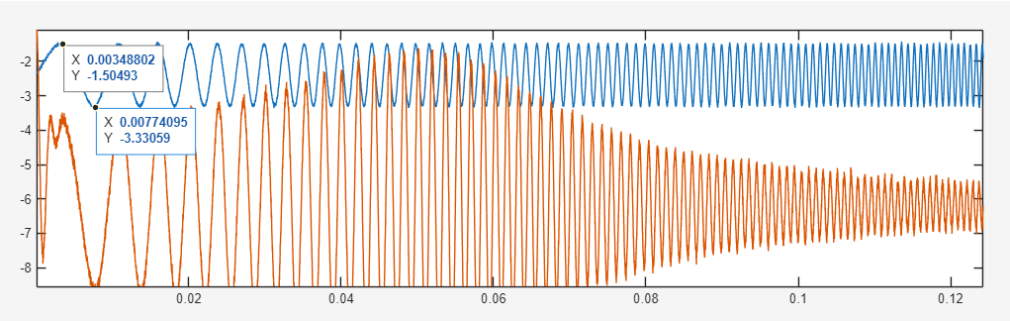

Figura 4.4 - Au

4.3. Determinarea modulului de rezonanță

Modulul de rezonanță se calculează cu ajutorul relației:

$$M_r = \frac{A_{yr}}{A_{ur}} \qquad \text{, în cazul meu } M_r \approx 4.8253$$

unde A_{yr} este jumatate din suma coordonatelor Y ale lui y_{max} si y_{min} din cea mai mare oscilație, iar A_{ur} este jumatate din suma coordonatelor Y ale lui u_{max} si u_{min} din cea mai mare oscilație

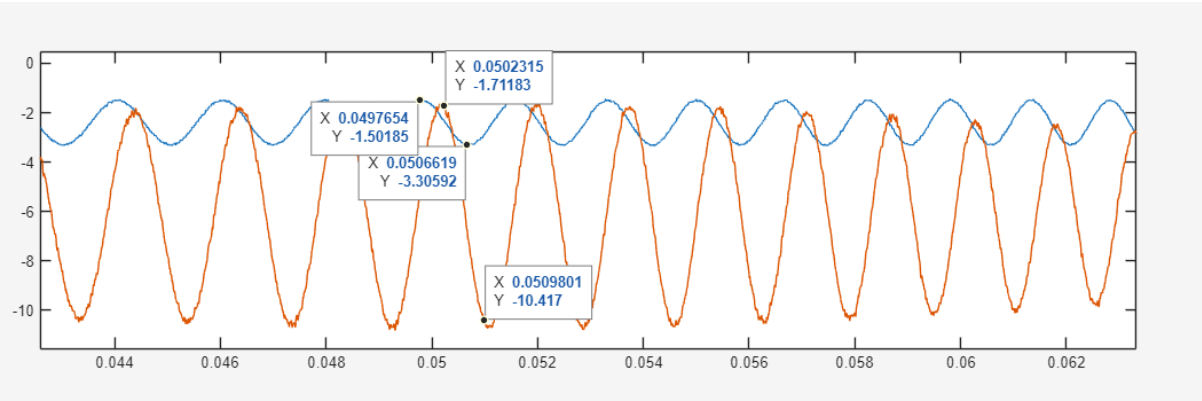

Figura 4.5 - Ayr, Aur

4.4. Determinarea pulsației naturale si factorului de amortizare

Pulsația naturală se calculează cu ajutorul relației:

$$\omega_n = \frac{\omega_r}{\sqrt{1-2\cdot\xi^2}},$$

unde $\omega_r = \frac{2\pi}{T_{osc}}$, dar $T_{osc} = 2 \cdot (t_{max} - t_{min})$, deci $\omega_r = \frac{\pi}{(t_{max}-t_{min})}$
In urma calculelor, valoare pulsației este de:

$$\omega_n = 3.814 \cdot 10^3$$

Factorul de amortizare se calculează cu ajutorul relației:

$$M_r = \frac{1}{2\zeta\sqrt{1-\xi^2}}$$

Această expresie se poate transforma într-o ecuație algebrică în ζ, care permite determinarea numerică a soluțiilor.

$$4M_r^2\zeta^4 - 4M_r^2\zeta^2 + K^2 = 0$$

Folosind comanda roots in Matlab, am reușit să afu valoare lui ζ

$$\zeta = 0.2775$$

4.5. Validarea

Pentru verificarea rezultatelor, răspunsul modelului a fost comparat cu răspunsul măsurat, realizând suprapunerea semnalelor în timp. Simularea s-a efectuat atât prin funcția de

transfer (condiții inițiale nule), cât și prin modelul echivalent în spațiul stărilor, ceea ce permite și analiza cu condiții inițiale nenule.

Rezultatul suprapunerii este:

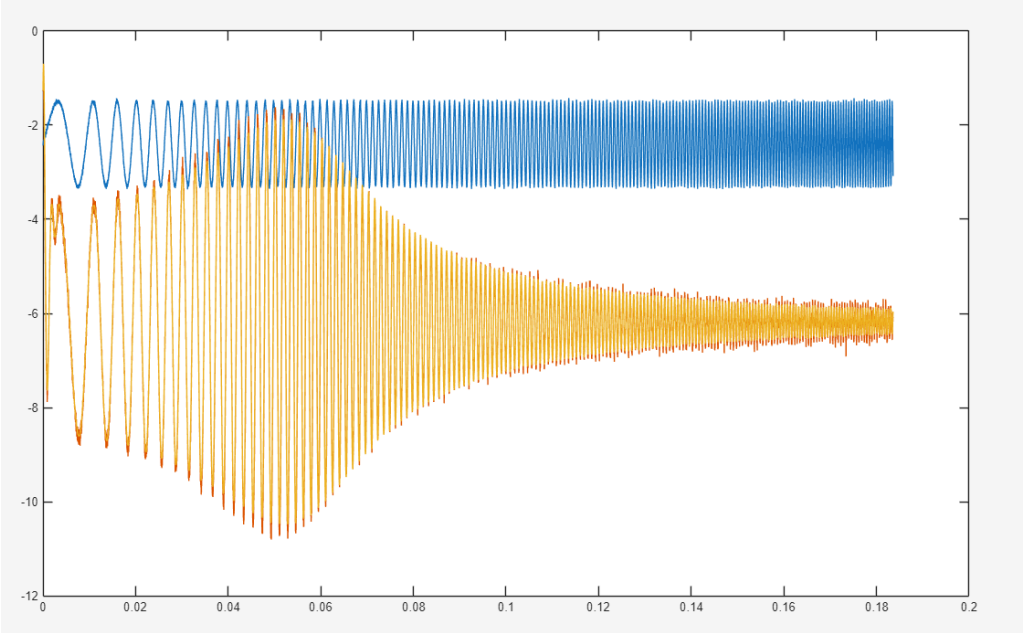

Figura 4.6 - Validarea

4.6. Funcția de cost și Eroarea medie pătratică

Pentru calcularea celor doi indici de performanță vom folosi

$$J = \frac{1}{\sqrt{N}} \left|\left|y - y_{sim}\right|\right| \qquad \varepsilon_{MPN} = \frac{\left|\left|y - y_{sim}\right|\right|}{\left|\left|y - \bar{y}\right|\right|} \cdot 100$$

Astfel, valorile calculate sunt:

$$J = 0.0293 \qquad \varepsilon_{MPN} = 9.5219$$

METODE PARAMETRICE

5. IDENTIFICAREA SISTEMELOR UTILIZÂND METODE PARAMETRICE

5.1. Scopul principal

Scopul principal este de a obține modele valide ale sistemului pentru diferite structuri:

- Modele validate prin autocorelație: ARX, ARMAX
- Modele validate prin intercorelație: iv4, OE, BJ
- Modele de altă natură: n4sid, ssest, ssregest

5.2. Pre-procesarea datelor

Înainte de identificarea propriu-zisă, datele au fost procesate pentru a asigura o identificare corectă a modelelor liniare.

- **Selecția datelor**

  S-au ales manual indicii pentru două ferestre de timp distincte:

  - **Date de Identificare (i1, i2):** Folosite pentru antrenarea modelului.
  - **Date de Validare (i3, i4):** Folosite pentru testarea performanței modelului

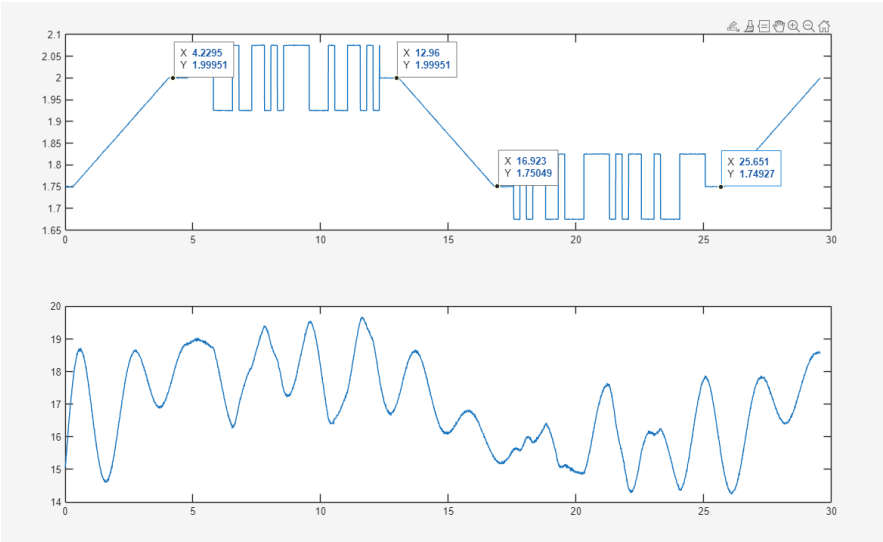

Figura 5.1 - Indicii i1-i4

- **Decimarea**: S-a aplicat o decimare a datelor, reprezentat prin N, in cazul nostru N=11
- **Eliminarea Componentei de Curent Continuu :** S-a scăzut media din semnale (u - mean(u) și y - mean(y)).

Pe baza indicilor selectați anterior, au fost extrase porțiunile de identificare și validare pentru semnalele de intrare și de ieșire. Pentru vizualizare, am generat o figură 2x2: prima linie conține semnalele de intrare pentru identificare și validare, iar a doua linie conține semnalele de ieșire pentru aceleași zone.

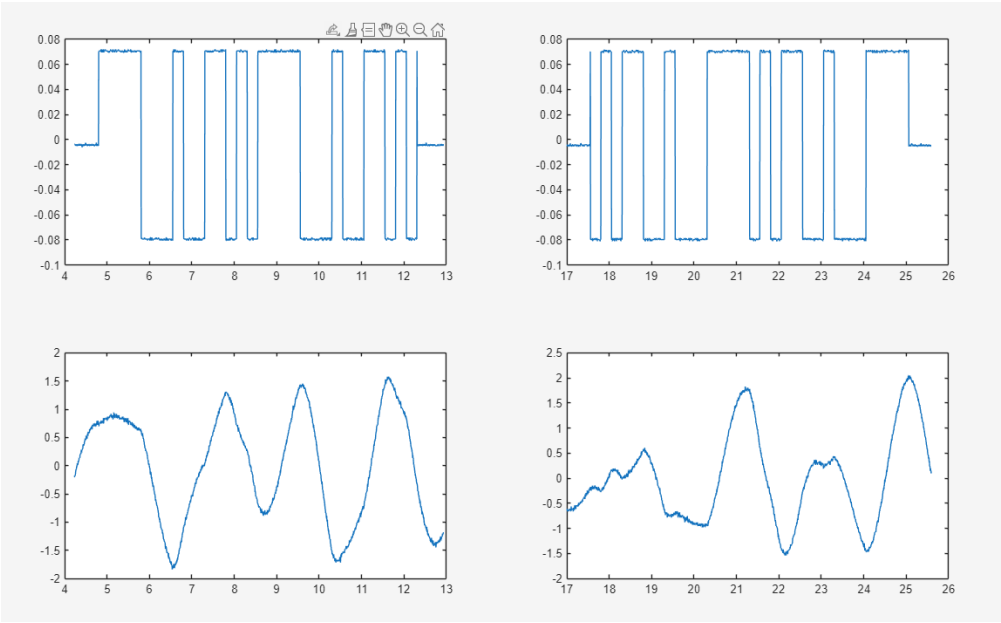

Figura 5.2

Pentru realizarea procedurii de identificare, datele experimentale au fost segmentate și organizate în structuri de tip iddata, specifice fiecărui subset (identificare, respectiv validare).

```
dat_id = iddata(y_id, u_id, t_id(2)-t_id(1));
dat_vd = iddata(y_vd, u_vd, t_vd(2)-t_vd(1));
```

5.3. Estimarea Modelelor

Conform cerințelor, au fost identificate trei categorii de modele, variind ordinele polinoamelor pentru a obține validarea statistică.

5.3.a) Modele variate prin autocorelație

Modelul **ARX** a fost testat inițial, însă nu a reușit să valideze testul de autocorelație. Pe de altă parte, modelul **ARMAX** a validat atâat criteriul de performanță, cât și de autocorelație.

- Parametrii
  n_a - ordinul polinomului $A(z-1)$, nr. polilor sistemului
  n_b - ordinul polinomului $B(z-1)$, nr. zerourilor + 1
  n_c - ordinul polinomului $C(z-1)$
  n_k - întârzierea dintre intrare și ieșire

În cazul nostru, am ales `model_armax = armax(dat_id, [3,3,4,2])`

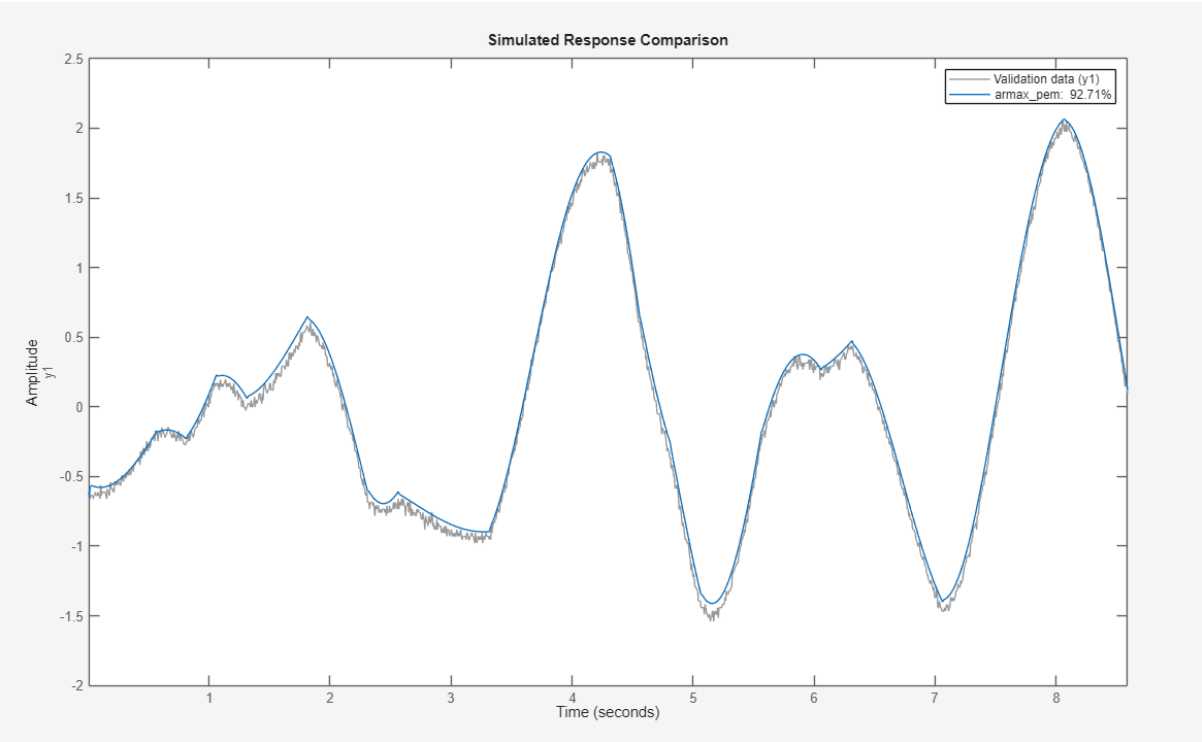

Figura 5.3 - Criteriul de performanță

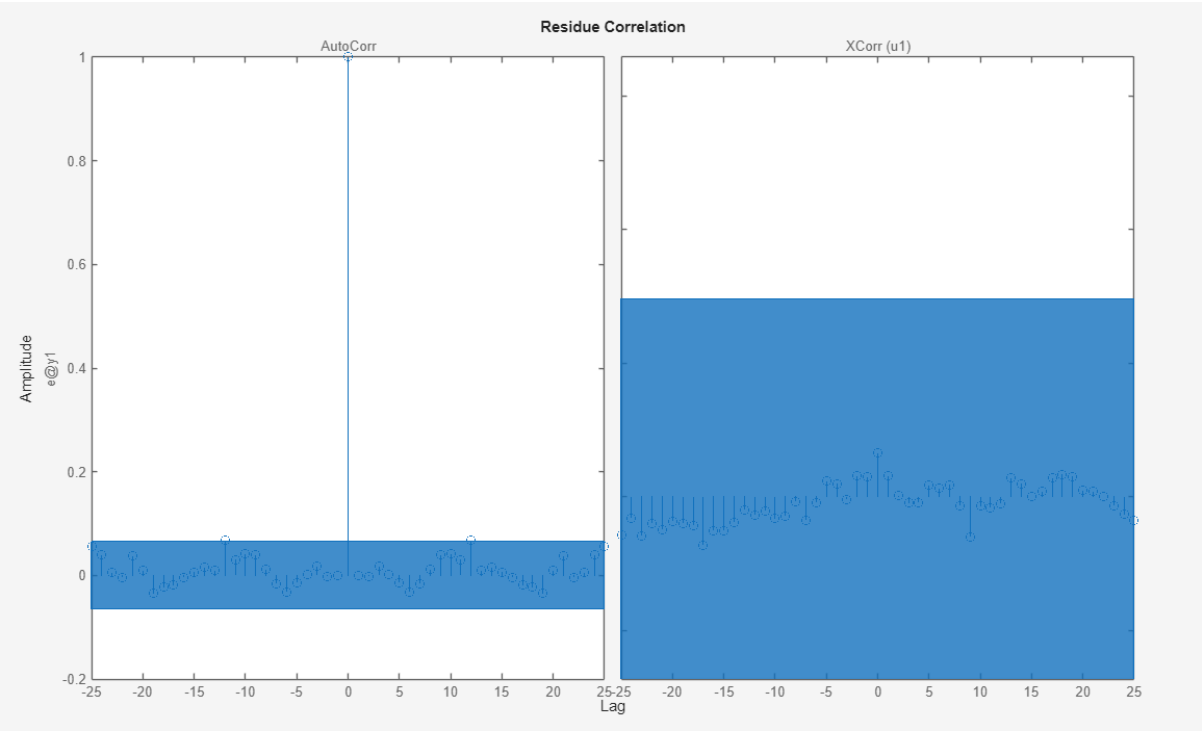

Figura 5.4 - Autocorelația

5.3.b) Modele variate prin intercorelație

Am testat modelul OE și acesta a reușit să treacă și el ambele teste: cel de performanță și testul de intercorelație

- Parametrii
  n_b - ordinul polinomului $B(z-1)$, nr. zerourilor + 1
  n_f - ordinul polinomului $F(z-1)$
  n_k - întârzierea dintre intrare și ieșire

În cazul nostru, am ales `model_oe = oe(dat_id, [3,3,1])`

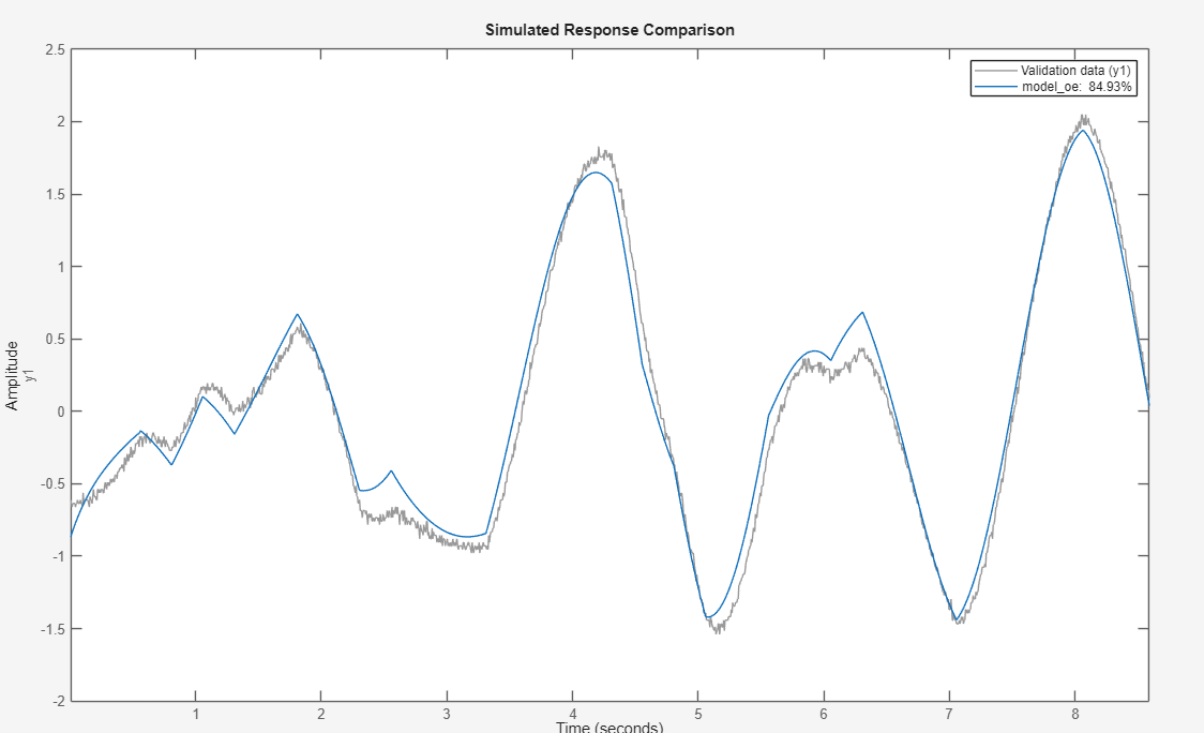

Figura 5.5 - Criteriul de performanță

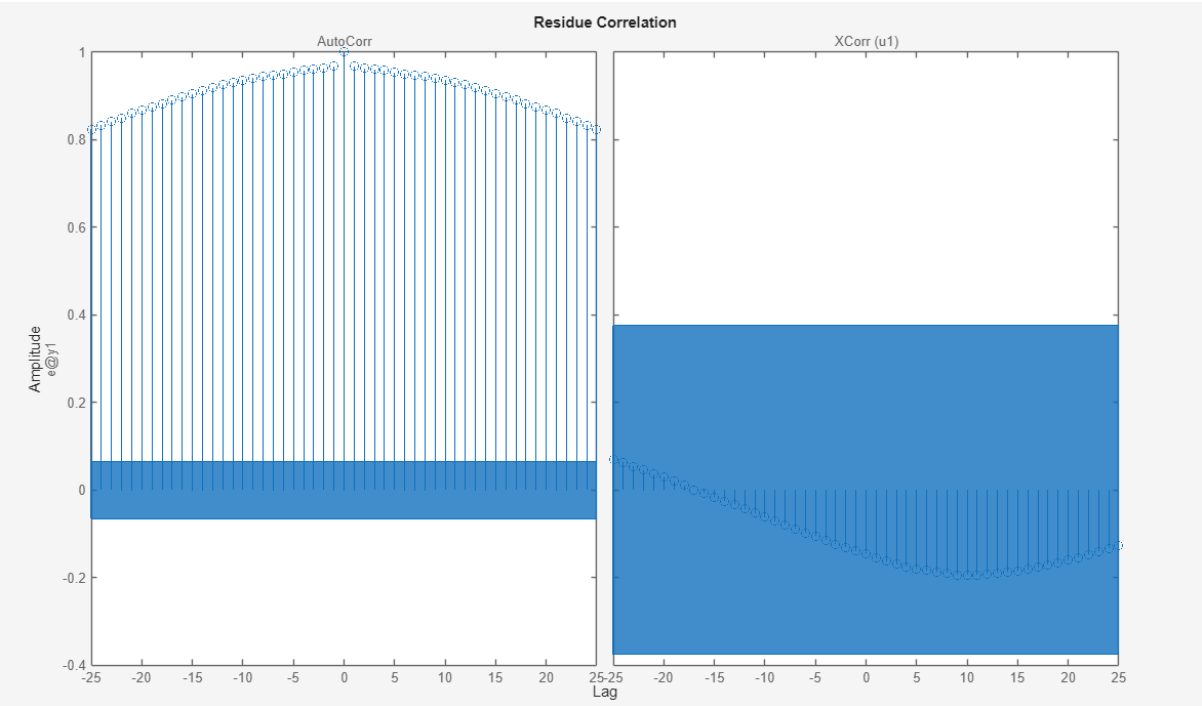

Figura 5.6 - Testul de intercorelație

5.3.c) Modele de altă natură

Am testat modelul SSEST și acesta a reușit, de asemenea să treacă ambele teste: cel de performanță și testul de intercorelație

```
model_ssest = ssest(dat_id, 2)
```

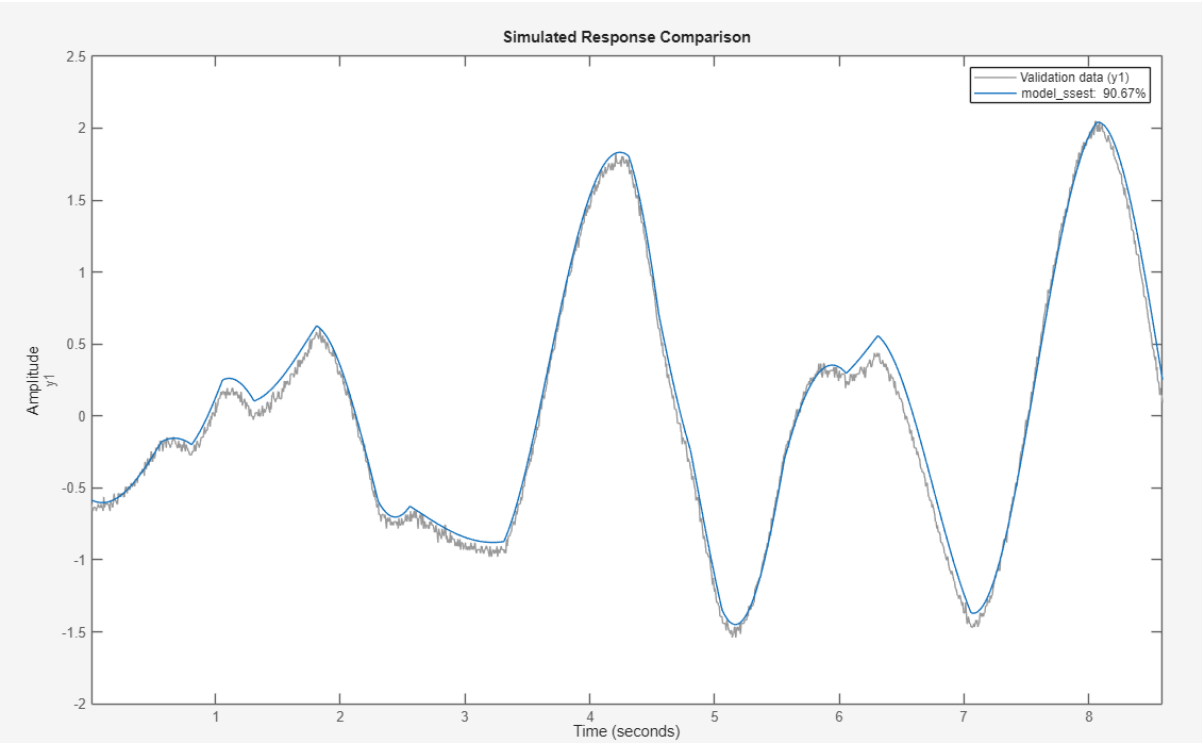

Figura 5.7 - Testul de performanță

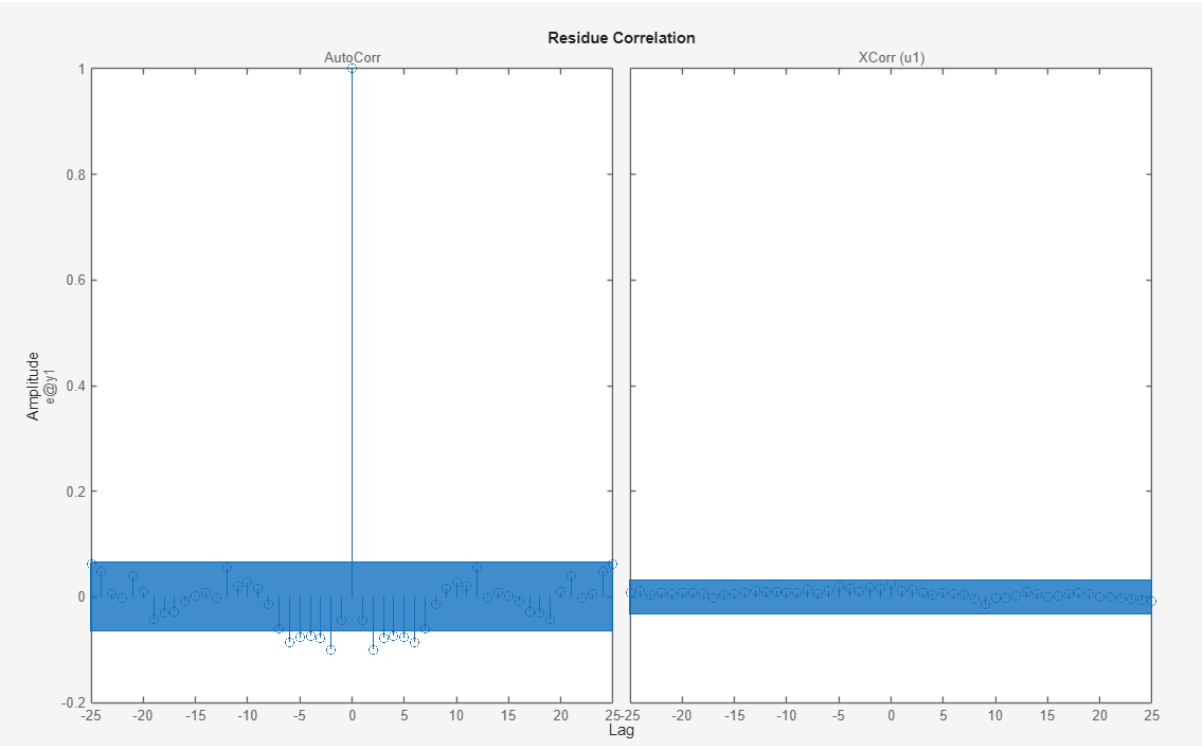

Figura 5.8 - Testul de autocorelație/intercorelație

5.4. Poli și zerouri

ARMAX:

- Poli: $s_{1,2} = 0.9981 \pm 0.0161i$ și $s_3 = 0.0519$
- Zerouri: $s_1 = 0.9613 \quad s_2 = 0.6486$

OE:

- Poli: $s_{1,2} = 0.9987 \pm 0.0162i$ și $s_3 = 0.9768$
- Zerouri: $s_{1,2} = 0.9843 \pm 0.0149i$

SSEST:

- Poli: $s_{1,2} = -0.2979 \pm 2.9186i$
- Zerouri: $s_1 = -6.4093$

5.5. Concluzie

Model	FIT [%]	Eroare(100%-FIT%)
ARMAX	92.71	7.29
OE	84.93	15.07
SSEST	90.67	9.33

În cadrul acestui proiect de identificare a sistemului, au fost determinate, analizate și validate trei structuri de model distincte: **ARMAX**, **OE** și **SSEST**. Obiectivul a fost obținerea unui model matematic care să descrie cu fidelitate dinamica procesului (pendulului), validat pe un set de date distinct de cel utilizat la antrenare.

Toate cele trei modele propuse au trecut cu succes testele de validare a reziduurilor. Analiza grafică a funcțiilor de autocorelație și intercorelație a demonstrat că reziduurile se încadrează în banda de încredere, ceea ce indică faptul că modelele au extras corect informația utilă din date, erorile rămase fiind de tip zgomot alb și necorelate cu intrarea.

Toate cele trei modele propuse au trecut cu succes testele de validare a reziduurilor. Analiza grafică a funcțiilor de autocorelație și intercorelație a demonstrat că reziduurile se încadrează în banda de încredere, ceea ce indică faptul că modelele au extras corect informația utilă din date, erorile rămase fiind de tip zgomot alb și necorelate cu intrarea.

- **Modelul ARMAX** a obținut cea mai ridicată performanță, cu un grad de potrivire de **92.71%** (eroare relativă de doar 7.29%).
- **Modelul SSEST** s-a clasat pe locul al doilea, cu un Fit de **90.67%**, demonstrând robustețea metodelor de subspațiu, fiind foarte aproape de performanța modelului ARMAX.
- **Modelul OE** a înregistrat cea mai scăzută performanță dintre cele trei, cu un Fit de **84.93%** (eroare 15.07%), indicând faptul că, pentru acest set de date, structura OE nu a reușit să surprindă la fel de bine complexitatea sistemului comparativ cu celelalte două metode.

Deși toate modelele sunt corecte din punct de vedere statistic, modelul **ARMAX** oferă cea mai fidelă predicție a ieșirii sistemului pe date necunoscute. Diferența de aproximativ **2%** față de SSEST și de peste **7%** față de OE este semnificativă, justificând alegerea sa pentru etapele ulterioare de proiectare a regulatorului automat. Modelul a demonstrat cel mai bun echilibru între capacitatea de a modela dinamica sistemului și cea de a compensa efectul perturbațiilor.